Taller 3 - Análisis de Sentimientos

Daniel Alejandro Chimbi León

Edna Valentina Henao Barrera

Daniel Felipe Sanchez Mogollón

Facultad de Ingeniería, Universidad El Bosque

Big Data Analytics

Fabian Camilo Peña Lozano

28 de noviembre de 2021

PARTE 1 - Para construir un mejor modelo se requieren más datos etiquetados

Para aumentar el número de datos etiquetados, se aumenta el dato numérico de la variable text-size el cual nos permite subir de 100 en 100. Seguido de cada imagen en el que se incrementa la variable, se puede observar los datos Recall y F1 en los que se puede detallar el aumento de los mismos.

Para 100

F1: 0.28

```
Para 200
 X_train, X_test, y_train, y_test = train_test_split(tweets_labeled_df['full_text'], tweets_labeled_df['sentiment'], test_size = 0.47
X_train.shape
 (224,)
pd.Series(y_train).value_counts(normalize = True)
     0.361607
 Name: sentiment, dtype: float64
X test.shape
 pd.Series(y_test).value_counts(normalize = True)
 0.0 0.635
     0.365
 Name: sentiment, dtvpe: float64
 print('Precision:', precision_score(y_test, y_test_bow_predict))
 print('Recall:', recall_score(y_test, y_test_bow_predict))
 print('F1:', f1_score(y_test, y_test_bow_predict))
 Precision: 0.41304347826086957
 Recall: 0.2602739726027397
 F1: 0.31932773109243695
Para 300
 X_train, X_test, y_train, y_test = train_test_split(tweets_labeled_df['full_text'], tweets_labeled_df['sentiment'], test_size = 0.706
 (124,)
 pd.Series(y_train).value_counts(normalize = True)
     0.637097
```

```
X train.shape
    0.362903
Name: sentiment, dtype: float64
X test.shape
(300,)
pd.Series(y_test).value_counts(normalize = True)
0.0 0.636667
    0.363333
Name: sentiment, dtype: float64
print('Precision:', precision_score(y_test, y_test_tfidf_predict))
print('Recall:', recall_score(y_test, y_test_tfidf_predict))
print('F1:', f1_score(y_test, y_test_tfidf_predict))
```

Precision: 0.4

Recall: 0.07339449541284404 F1: 0.12403100775193798

PARTE 2 - El entrenamiento se está realizando con datos mal etiquetados

BOW ANTES

Anteriormente la variable bow mostraba una matriz de confusión más pequeña y la precisión es más baja en comparación.

BOW DESPUÉS

Al finalizar, el modelo maneja una matriz de confusión más grande y una precisión mayor, mejorando el resultado de las métricas.

Training and evaluating a model using BOW

```
logistic_model = LogisticRegression(random_state = 2)
3]: logistic_model.fit(X_bow, y_train)
3]: LogisticRegression(random_state=2)
    y_train_bow_predict = logistic_model.predict(X_bow)
    y_test_bow_predict = logistic_model.predict(bow.transform()
    confusion_matrix(y_train, y_train_bow_predict)
5]: array([[216, 0],
           [ 0, 123]], dtype=int64)
    confusion_matrix(y_test, y_test_bow_predict)
6]: array([[44, 10],
           [23, 8]], dtype=int64)
   print('Precision:', precision_score(y_test, y_test_bow_pre-
    print('Recall:', recall_score(y_test, y_test_bow_predict))
    print('F1:', f1_score(y_test, y_test_bow_predict))
    Recall: 0.25806451612903225
    F1: 0.32653061224489793
```

TF-IDF ANTES

Anteriormente el modelo TF-IDF mostraba una matriz de confusión más pequeña y la precisión es más baja en comparación.

Training and evaluating a model using TF-IDF

```
logistic_model = LogisticRegression(random_state = 2)
logistic model.fit(X tfidf, y train)
LogisticRegression(random state=2)
y_train_tfidf_predict = logistic_model.predict(X_tfidf)
y_test_tfidf_predict = logistic_model.predict(bow.transform(X_test))
confusion_matrix(y_train, y_train_tfidf_predict)
array([[1839,
               4],
       [ 643, 525]], dtype=int64)
confusion_matrix(y_test, y_test_tfidf_predict)
array([[1566, 276],
       [ 952, 217]], dtype=int64)
print('Precision:', precision_score(y_test, y_test_tfidf_predict))
print('Recall:', recall_score(y_test, y_test_tfidf_predict))
print('F1:', f1_score(y_test, y_test_tfidf_predict))
Precision: 0.44016227180527384
Recall: 0.18562874251497005
F1: 0.2611311672683514
```

TF-IDF DESPUÉS

Al finalizar, el modelo maneja una matriz de confusión más grande y una precisión mayor, mejorando el resultado de las métricas.

Training and evaluating a model using TF-IDF

```
[28]: logistic_model = LogisticRegression(random_state = 2)
[29]: logistic_model.fit(X_tfidf, y_train)
[29]: LogisticRegression(random_state=2)
[30]: y_train_tfidf_predict = logistic_model.predict(X_tfidf)
      y_test_tfidf_predict = logistic_model.predict(bow.transform(X_test))
      confusion matrix(y train, y train tfidf predict)
[31]:
[31]: array([[216, 0],
             [ 67, 56]], dtype=int64)
     confusion_matrix(y_test, y_test_tfidf_predict)
[32]: array([[51, 3],
             [25, 6]], dtype=int64)
      print('Precision:', precision_score(y_test, y_test_tfidf_predict))
      print('Recall:', recall score(y test, y test tfidf predict))
      print('F1:', f1_score(y_test, y_test_tfidf_predict))
      Precision: 0.666666666666666
      Recall: 0.1935483870967742
      F1: 0.3000000000000000004
```

LINK DE YOUTUBE: https://youtu.be/53HglE4RNbY